

HW3 CUDA Core 및 Tensor Core를 사용한 Jacobi Iteration의 구현

20211402 김세준

1. 디바이스 정보

```
CUDA Device Query (Runtime API) version (CUDART static linking)

Detected 1 CUDA Capable device(s)

Device 0: "NVIDIA GeForce RTX 4080 SUPER"
  CUDA Driver Version / Runtime Version      13.2 / 13.2
  CUDA Capability Major/Minor version number: 8.9
  Total amount of global memory:             16376 MBytes (17170956288 bytes)
  (0800) Multiprocessors, (128) CUDA Cores/MP: 10240 CUDA Cores
  GPU Max Clock rate:                       2595 MHz (2.60 GHz)
  Memory Clock rate:                        11501 Mhz
  Memory Bus Width:                         256-bit
  L2 Cache Size:                           67108864 bytes
  Maximum Texture Dimension Size (x,y,z)    1D=(131072), 2D=(131072, 65536), 3D=(16384, 16384, 16384)
  Maximum Layered 1D Texture Size, (num) layers 1D=(32768), 2048 layers
  Maximum Layered 2D Texture Size, (num) layers 2D=(32768, 32768), 2048 layers
  Total amount of constant memory:          65536 bytes
  Total amount of shared memory per block:   49152 bytes
  Total shared memory per multiprocessor:    102400 bytes
  Total number of registers available per block: 65536
  Warp size:                                32
  Maximum number of threads per multiprocessor: 1536
  Maximum number of threads per block:      1024
  Max dimension size of a thread block (x,y,z): (1024, 1024, 64)
  Max dimension size of a grid size (x,y,z): (2147483647, 65535, 65535)
  Maximum memory pitch:                     2147483647 bytes
  Texture alignment:                        512 bytes
  Concurrent copy and kernel execution:     Yes with 1 copy engine(s)
  Run time limit on kernels:                 Yes
  Integrated GPU sharing Host Memory:        No
  Support host page-locked memory mapping:  Yes
  Alignment requirement for Surfaces:        Yes
  Device has ECC support:                    Disabled
  CUDA Device Driver Mode (TCC or WDDM):     WDDM (Windows Display Driver Model)
  Device supports Unified Addressing (UVA):  Yes
  Device supports Managed Memory:            Yes
  Device supports Compute Preemption:        Yes
  Supports Cooperative Kernel Launch:        Yes
  Device PCI Domain ID / Bus ID / location ID: 0 / 1 / 0
  Compute Mode:
    < Default (multiple host threads can use ::cudaSetDevice() with device simultaneously) >

deviceQuery, CUDA Driver = CUDART, CUDA Driver Version = 13.2, CUDA Runtime Version = 13.2, NumDevs = 1
Result = PASS
```

```
nvcc: NVIDIA (R) Cuda compiler driver
Copyright (c) 2005-2025 NVIDIA Corporation
Built on Tue_Dec_16_19:27:18_Pacific_Standard_Time_2025
Cuda compilation tools, release 13.1, V13.1.115
Build cuda_13.1.r13.1/compiler.37061995_0
```

Compute Capability 8.9, CUDA Toolkit 13.1 설치됨.

2. 실험

실험은 matrix_size가 1024, 2048, 4096인 행렬을 대상으로 했고, 2가지를 진행했다. 첫 번째는 정밀도를 측정하기 위해 matrix_size가 1024인 행렬을 대상으로 device 함수의 짝수 번째 iteration이 끝날 때마다 cpu로 행렬을 올려서 final_relative_residual_norm의 값을 확인

했다.

```
Microsoft Visual Studio 디버그 콘솔
FPS N/A N/A | GPU 15% 35°C 0 RPM | CPU 5% | 지연시간 N/A

>>> [HOST]
>>> Trying to solve for X in UX = V of size 1024 using 20 maximum Jacobi iterations...
.....
>>> The final relative residual error after 6 iterations ||R||/||V|| = ||UX - V||/||V|| is 4.960132e-08.
>>> Total execution time using host: 43953.055 ms>>> Jacobi iteration completed successfully.

>>> [CUDA CORE]
>>> Trying to solve for X in UX = V of size 1024 using 20 maximum Jacobi iterations...
..
After 02 iterations, the relative error is: ||R||/||V|| = 3.183616e-02..
After 04 iterations, the relative error is: ||R||/||V|| = 3.532786e-05..
After 06 iterations, the relative error is: ||R||/||V|| = 5.234583e-08.
>>> The final relative residual error after 6 iterations ||R||/||V|| = ||UX - V||/||V|| is 5.234583e-08.
>>> Total execution time using CUDA core: 21.115 ms>>> Jacobi iteration completed successfully.

>>> [TENSOR CORE]
>>> Trying to solve for X in UX = V of size 1024 using 20 maximum Jacobi iterations...
..
After 02 iterations, the relative error is: ||R||/||V|| = 3.180049e-02..
After 04 iterations, the relative error is: ||R||/||V|| = 4.304432e-05..
After 06 iterations, the relative error is: ||R||/||V|| = 2.385877e-05..
After 08 iterations, the relative error is: ||R||/||V|| = 2.378162e-05..
After 10 iterations, the relative error is: ||R||/||V|| = 2.378296e-05..
After 12 iterations, the relative error is: ||R||/||V|| = 2.378664e-05..
After 14 iterations, the relative error is: ||R||/||V|| = 2.378435e-05..
After 16 iterations, the relative error is: ||R||/||V|| = 2.379298e-05..
After 18 iterations, the relative error is: ||R||/||V|| = 2.379333e-05..
After 20 iterations, the relative error is: ||R||/||V|| = 2.379510e-05.
>>> The final relative residual error after 20 iterations ||R||/||V|| = ||UX - V||/||V|| is 2.379510e-05.
>>> Total execution time using Tensor core: 89.274 ms>>> Jacobi iteration failed to converge (Error Code: 1).

>>> Average execution time on CUDA core: 21.115
>>> Average execution time on Tensor core: 89.274
Release\JacobiSolver.exe(프로세스 3732)이(가) 0 코드(0x0)와 함께 종료되었습니다.
이 창을 닫으려면 아무 키나 누르세요...
```

Relative Error	Host	CUDA Core	Tensor Core
2	-	3.183616e-02	3.180049e-02
4	-	3.532786e-05	4.304432e-05
6	4.960132e-08	5.234583e-08	2.385877e-05
8	-	-	2.378162e-05
10	-	-	2.378296e-05
12	-	-	2.378664e-05
14	-	-	2.378435e-05
16	-	-	2.379298e-05
28	-	-	2.379333e-05
20	-	-	2.379510e-05

시간 측정은 함수 수정 전에 측정한 부분이라 부정확한 사항이 있을 수 있음.

우선 host와 CUDA core를 비교하자면, 같은 시점에 converge 판정을 받았고, 상대 오차의 정밀도가 동일한 모습을 보인다. 이는 동일한 FP32를 이용해서 연산을 했기 때문이다. 다만 정확하게 같은 값을 가지지 않은 이유는 cpu와 gpu의 부동소수점 연산 방식이 다르기 때문이다.

CUDA core와 tensor core를 비교하자면, 4번째 iteration까지는 비슷한 정밀도까지 상대 오차를 줄였지만, 이후부터 그 이상으로 정밀하게 오차를 감소시키지 못했다. 이는 wmma에서 행렬 A와 B의 자료형을 TF32로 사용하여 정밀도 10비트짜리 연산을 진행했기에, FP32에서 사용한 정밀도 23비트짜리 연산처럼 상대 오차를 줄일 수 없었기 때문이다. 또한 이 때문에 20번의 iteration을 사용했어도 failed to converge 판정이 났다. TF32를 사용해서 특정 범위 이내로 오차를 줄일 수 없었기 때문이다.

다음 실험은 본격적인 시간 측정이다. 3종류의 행렬을 대상으로 host 1회, 나머지 커널은 10회씩 측정한 것의 평균을 비교했다. 시간 단축을 위해서, MAX_ITERATIONS = 6으로 설정했다. 측정 단위는 전부 ms이다.

```

Microsoft Visual Studio 디버그
>>> Trying to solve for X in UX = V of size 4096 using 6 maximum Jacobi iterations...
>>> The final relative residual error after 6 iterations ||R||/||V|| = ||UX - V||/||V|| is 2.390268e-05.
>>> Total execution time using Tensor core: 44.638 ms
>>> Jacobi iteration failed to converge (Error Code: 1).
>>> [CUDA CORE]
>>> Trying to solve for X in UX = V of size 4096 using 6 maximum Jacobi iterations...
>>> The final relative residual error after 6 iterations ||R||/||V|| = ||UX - V||/||V|| is 3.434411e-08.
>>> Total execution time using CUDA core: 101.238 ms
>>> Jacobi iteration completed successfully.
>>> [TENSOR CORE]
>>> Trying to solve for X in UX = V of size 4096 using 6 maximum Jacobi iterations...
>>> The final relative residual error after 6 iterations ||R||/||V|| = ||UX - V||/||V|| is 2.390268e-05.
>>> Total execution time using Tensor core: 165.546 ms
>>> Jacobi iteration failed to converge (Error Code: 1).
>>> Average execution time on CUDA core: 100.532
>>> Average execution time on Tensor core: 93.081
Release\JacobiSolver.exe(프로세스 21012)이(가) 0 코드(0x0)와 함께 종료되었습니다.
이 창을 닫으려면 아무 키나 누르세요...

```

i	Host	CUDA Core	Tensor Core
1	45448.633	13.107	2.144
2		2.297	12.450
3		36.425	21.732
4		36.332	16.468
5		35.812	26.917
6		40.264	15.281
7		87.312	9.767
8		33.594	22.080
9		40.408	24.360
10		34.471	26.037
Average		36.002	17.724

Table 2: Average execution time [ms] in matrix_size=1024

i	Host	CUDA Core	Tensor Core
1	446983.156	111.651	74.655
2		180.491	75.122
3		164.266	72.917
4		164.452	73.581
5		167.035	116.008
6		169.794	74.765
7		129.738	74.326
8		142.943	74.961
9		162.160	74.434
10		116.498	88.702
Average		150.903	79.947

Table 3: Average execution time [ms] in matrix_size=2048

i	Host	CUDA Core	Tensor Core
1	3690186.750	100.586	151.257
2		100.512	57.541
3		100.486	44.493
4		100.270	44.502
5		100.187	104.999
6		100.198	44.506
7		100.338	133.714
8		101.249	139.611
9		100.259	44.638
10		101.238	165.546
Average		100.532	93.081

Table 4: Average execution time [ms] in matrix_size=4096

matrix_size	CUDA vs Host	Tensor vs Host	Tensor vs CUDA
1024	1262	2564	2.031
2048	2962	5590	1.888
4096	36707	39645	1.080

Table 5: Average Speedup depending on matrix_size

확실히 host와 비교했을 때 TF32를 활용한 연산이 더 우위에 있었고, CUDA core의 FP32 연산과도 비교해봤을 때 더 우위를 점한 것을 확인했다. 위에서 확인한 정밀도를 고려했을 때, 소수점 아래 4~5자리까지의 정밀도만을 요구한다면 FP32보다는 TF32를 사용하는 것이 더 유리하다고 볼 수 있다.

다만 연산량이 많아질수록 이 차이는 급격하게 줄었는데, tensor core 연산을 할 때 측정 시간이 엄청 널뛰기해서 평균이 많이 높아지는 것을 확인했다. 아마도 wmma를 활용하는 과정에서 TF32를 FP32로 변환하는 과정에서 문제가 생기지 않았을까 추측한다. 그렇기에 FP16을 활용하고, 더 큰 matrix_size에서 실험을 해본다면 또 다른 결과를 얻을 수 있으리라 추측한다.

3. 코드

기본적으로 커널에 대해 설명할 것은 크게 없다. 결국 강의자료의 shared memory를 활용한 2개의 커널을, $C=A*B+C$ 가 아니라 $D=A*B+C$ 로 작동하게끔 변환한 것이다. Host와 동일하게 D와 B의 역할을 바꿔가며 MMA 연산을 하도록 했다. 다른 기능들도 90% 이상 host와 동일하니 이에 대한 설명은 생략한다.

Jacobi.h의 매크로 `_USE_DEVICE_DEBUG`를 통해 0이면 오차 로그 없이, matrix_size의 1, 2, 4배의 크기에 대해 총 10회의 반복을 해서 execution time 평균을 내게 했고, 1이면 matrix_size의 1배의 크기에 대해 1회만의 반복으로 해서 오차 로그를 내도록 설계했다.

기본적으로 커널의 속도가 아무리 빨라도 결국 행렬을 cudaMemcpy를 통해 다시 cpu로 보내서 converge 여부를 판단해야 하기 때문에 이 부분이 병목으로 자리잡을 수밖에 없다. 따라서 만약에 이 부분을 device 함수로 구현할 수 있다면 전체적인 프로그램의 속도가 훨씬 빨라질 수 있을 것이고, 그때가 되면 시간 측정을 커널에 대해서만이 아닌, 전체 수행 과정에 대해 측정할 수 있게 되어 실용성을 높일 수 있을 것이다.

이번 과제에서는 해당 사항이 없겠지만, 만약 converge하지 않는 경우를 대비해서 debug

모드일 때는 짝수번 iteration마다 행렬을 cpu로 보내서 isnan과 isinf를 측정하고 이로 인해 실패했으면 마지막으로 성공한 행렬을 결과로 가져갈 수 있게 했다. 행렬 자체, 혹은 정밀도로 인해서 생기는 문제가 있을 수도 있기 때문인데 나중에 이러한 부분을 전부 device에서 동작하게 하고 더 일반적인, 예를 들어 확률적으로 수렴하는 행렬들에 대해 동작하도록 하여 실험하는 것도 좋을 것 같다.